端侧 AI 推理性能优化与 seekdb 混合检索

Local Lexicon：浏览器本地向量化 · seekdb 单次全文 + 向量混合检索 · WebGPU 优先与 WASM 自动降级

1.9989×	25.15 ms	1.000
FP32 → FP16 权重压缩比	FP16 + WebGPU 端到端中位数	FP16 与 FP32 的 Recall / MRR / nDCG

01 / 端侧推理与降级

Transformers.js 4.3.2 在专用 Web Worker 内加载 `onnx-community/all-MiniLM-L6-v2-ONNX`（revision `aff7a1dc`，Apache-2.0，384 维），文档与查询 embedding 均在用户设备计算。启动时探测 `navigator.gpu.requestAdapter()`：可用时显式选择 WebGPU + FP16；适配器缺失或初始化失败时自动回退到 WASM + FP16。界面持续显示实际后端，不使用云端 embedding API，也不回放预计算向量。

02 / 量化与质量

按 ONNX 图与外部权重文件统计：FP32 为 90,318,300 bytes，FP16 为 45,184,187 bytes，压缩比 1.9989，体积减少 49.97%。固定 8 文档、8 查询，同机 Edge/WebGPU 重复 3 次；FP16 的 Recall@1/3/5、MRR@5、nDCG@5 均为 1.000，与 FP32 的差值均为 0。该小集用于提交回归，不替代更大领域评测。

配置	8 文档向量化	吞吐	查询向量化	seekdb 检索	端到端	质量
FP32 + WebGPU	89.03 ms	89.86 docs/s	7.04 ms	—	—	1.000
FP16 + WebGPU	83.83 ms	95.43 docs/s	7.27 ms	4.58 ms	25.15 ms	1.000
FP16 + WASM	604.28 ms	13.24 docs/s	9.84 ms	4.54 ms	26.72 ms	1.000

文档向量化为 3 次中位数；查询与端到端为 5 次中位数。端到端从提交查询开始，包含 query embedding、HTTP、seekdb 混合检索和结果 DOM 渲染。测试环境：Windows 10.0.26200、Ryzen 7 9700X、RTX 5080、Edge 156、seekdb 1.4.0.0。

03 / seekdb 数据与刷新

每个知识库对应独立 collection，同时建立 smart IK 全文索引与 384 维 cosine HNSW；目录表和文档登记表持久化会话与内容哈希。写入采用确定性分块 ID 和 `upsert`，重复导入删除变短后的尾部旧分块。写后依次执行 `collection.refresh_index()` 和带 documentId 过滤的向量可见性轮询，只有新分块可检索才返回成功。

04 / 数据库内混合检索

查询时调用一次 `collection.hybridSearch()`：全文条件放在 query，浏览器生成的稠密向量放在 knn，数据库内以 **RRF**（`rankConstant=60`）融合；SDK 将其展开为 seekdb **`DBMS_HYBRID_SEARCH`**。客户端不会分别拉取两路候选再拼合。实测 8 文档、8 分块下，5 次检索中位数：WebGPU 4.58 ms，WASM 4.54 ms。

05 / 复现与证据

源码目录：`stepfun/`。启动：`npm ci → npm run init-db → npm run dev`；生产构建：`npm run build → npm run start:win`。单元测试 9/9、真实 seekdb 集成测试通过；独立无头 Edge 验证 WebGPU、移除 GPU 后的 自动 WASM、8 文档导入、索引刷新、5 次混合检索，以及临时空 collection 不串结果。原始 JSON、截图、Schema 与完整方法分别保存在 results/ 和 docs/。

INFERENCE LOCATION: THIS DEVICE · RETRIEVAL ENGINE: SEEKDB · RANK: RRF